

机器学习第五次作业

姓名：刘文晨

学号：202222280328

题目 1

题面：

从网上下载或自己编程实现 TSVM 算法 选择两个 UCI 数据集,将其中 30% 的样例用作测试样本, 10%的样例用作有标记样本, 60%的样例用作无标记样本。分别训练出利用无标记样本的 TSVM 以及仅利用有标记样本的 SVM, 并比较其性能。

解：

选择最常用的 iris 数据集, 将数据集标准化之后, 将其中 30 个样例用作测试样本, 10 个样例用作有标记样本, 60 个样例用作无标记样本。以 sklearn 的 SVM 算法为基础建立 TSVM。模型训练好后, 输出经过有标记的样本训练后对未标记样本的预测正确率、经过 TSVM 训练后, 对未标记样本的预测正确率和经过 TSVM 训练后对测试样本的预测正确率。最后绘制散点图和分别由 SVM 和 TSVM 得到的超平面。代码如下：

```
1. import matplotlib.pyplot as plt
2. import numpy as np
3. import pandas as pd
4. from sklearn import svm
5. from sklearn.datasets import load_iris
6. from sklearn.preprocessing import MinMaxScaler
7.
8.
9. def create_data():
10.     iris = load_iris()
11.     df = pd.DataFrame(iris.data, columns=iris.feature_names)
12.     df['label'] = iris.target
13.     df.columns = ['sepal length', 'sepal width', 'petal length', 'petal width', 'label']
14.     data = np.array(df.iloc[:100, [0, 1, -1]])
15.     # 对数据进行标准化处理
16.     sc = MinMaxScaler()
17.     sc.fit(data)
18.     data = sc.transform(data)
```

```

19.     data[:, -1] = data[:, -1] * 2 - 1
20.     # 30 个测试样本
21.     test = np.vstack((data[:15], data[50:65]))
22.     # 10 个有标记样本
23.     labeled_sample = np.vstack((data[15:20], data[65:70]))
24.     # 60 个无标记样本
25.     unlabeled_sample = np.vstack((data[20:50], data[70:]))
26.     return test, labeled_sample, unlabeled_sample
27.
28.
29.     test, labeled, unlabeled = create_data()
30.     clf = svm.SVC(C=1, kernel='linear')
31.     # 有标记的样本训练 SVM
32.     clf.fit(labeled[:, :2], labeled[:, -1])
33.     positive_labeled = labeled[5:]
34.     negative_labeled = labeled[:5]
35.     plt.scatter(labeled[:5, :2][:, 0], labeled[:5, :2][:, 1], color='red', s=40,
        label=-1)
36.     plt.scatter(labeled[5:, :2][:, 0], labeled[5:, :2][:, 1], color='blue', s=40
        , label=1)
37.     x_points = np.linspace(0, 1, 10)
38.     y_points = -
        (clf.coef_[0][0] * x_points + clf.intercept_) / clf.coef_[0][1]
39.     plt.plot(x_points, y_points, color='green')
40.     plt.legend()
41.     # 伪标记
42.     fake_label = clf.predict(unlabeled[:, :2])
43.     unlabeled_positive_x = []
44.     unlabeled_positive_y = []
45.     unlabeled_negative_x = []
46.     unlabeled_negative_y = []
47.     for i in range(len(unlabeled)):
48.         if int(fake_label[i]) == 1:
49.             unlabeled_positive_x.append(unlabeled[i, 0])
50.             unlabeled_positive_y.append(unlabeled[i, 1])
51.         else:
52.             unlabeled_negative_x.append(unlabeled[i, 0])
53.             unlabeled_negative_y.append(unlabeled[i, 1])
54.
55.     plt.scatter(unlabeled_positive_x, unlabeled_positive_y, color='red', s=15)
56.     plt.scatter(unlabeled_negative_x, unlabeled_negative_y, color='blue', s=15)
57.     print('经过有标记的样本训练后, 对未标记样本的预测正确率为
        {}'.format(clf.score(unlabeled[:, :2], unlabeled[:, -1])))

```

```

58.
59.     Cu = 0.1
60.     Cl = 1  # 初始化 Cu, Cl
61.     weight = np.ones(len(labeled) + len(unlabeled))
62.     # 样本权重
63.     weight[len(unlabeled):] = Cu
64.     # 用于训练有标记与无标记样本集合
65.     train_sample = np.vstack((labeled[:, :2], unlabeled[:, :2]))
66.     # 用于训练的标记集合
67.     train_label = np.hstack((labeled[:, -1], fake_label))
68.     unlabeled_id = np.arange(len(unlabeled))
69.
70.     while Cu < Cl:
71.         clf.fit(train_sample, train_label, sample_weight=weight)
72.         while True:
73.             # 通过训练得到的预测标记
74.             predicted_y = clf.decision_function(unlabeled[:, :2])
75.             # 伪标记, 这里为与预测的区分开, 写为 real_y
76.             real_y = fake_label
77.             epsilon = 1 - predicted_y * real_y
78.             positive_set, positive_id = epsilon[real_y > 0], unlabeled_id[real_y
> 0]
79.             negative_set, negative_id = epsilon[real_y < 0], unlabeled_id[real_y
< 0]
80.             positive_max_id = positive_id[np.argmax(positive_set)]
81.             negative_max_id = negative_id[np.argmax(negative_set)]
82.             epsilon1, epsilon2 = epsilon[positive_max_id], epsilon[negative_max_
id]
83.             if epsilon1 > 0 and epsilon2 > 0 and round(epsilon1 + epsilon2, 3) >
= 2:
84.                 fake_label[positive_max_id] = -fake_label[positive_max_id]
85.                 fake_label[negative_max_id] = -fake_label[negative_max_id]
86.                 train_label = np.hstack((labeled[:, -1], fake_label))
87.                 clf.fit(train_sample, train_label, sample_weight=weight)
88.             else:
89.                 break
90.             # 更新 Cu
91.             Cu = min(2 * Cu, Cl)
92.             # 更新样本权重
93.             weight[len(unlabeled):] = Cu
94.             # 绘图
95.             x_points = np.linspace(0, 1, 10)
96.             y_points = -
(clf.coef_[0][0] * x_points + clf.intercept_) / clf.coef_[0][1]

```

```

97. plt.plot(x_points, y_points, color='yellow')
98. plt.savefig('运行结果.jpg')
99. plt.show()
100. # 打印结果
101. print('经过 TSVM 训练后, 对未标记样本的预测正确率为
{}'.format(clf.score(unlabeled[:, :2], unlabeled[:, -1])))
102. print('经过 TSVM 训练后, 对测试样本的预测正确率为
{}'.format(clf.score(test[:, :2], test[:, -1])))

```

运行程序后, 我们得到: 经过有标记的样本训练后, 对未标记样本的预测正确率为 0.9666666666666667, 经过 TSVM 训练后, 对未标记样本的预测正确率为 0.9833333333333333, 经过 TSVM 训练后, 对测试样本的预测正确率为 1.0。




图 1 散点图与超平面

程序绘制的散点图和超平面如图 1 所示。其中, 绿线是仅利用有标记样本的 SVM 得到的超平面, 黄线是利用无标记样本的 TSVM 模型得到的超平面。

由实验结果可知, 对于 iris 数据集, TSVM 通过利用未标记数据能提高最终分类的准确率, 从 SVM 的 96.67%提高到了 TSVM 的 98.33%, 并且预测标记与测试集的真实标记一致, 预测正确率为 100%。

题目 2

题面：

假设数据由混合专家（mixture of experts）模型生成，即数据是基于 k 个成分混合而得的概率密度生成： $p(x|\theta) = \sum_{i=1}^k \alpha_i \cdot p(x|\theta_i)$ ，其中， $\theta = \{\theta_1, \theta_2, \dots, \theta_k\}$ 是模型参数， $p(x|\theta_i)$ 是第 i 个混合成分的概率密度，混合系数 $\alpha_i \geq 0$ ， $\sum_{i=1}^k \alpha_i = 1$ 。假设每个混合成分对应一个类别，但每个类别可能包含多个混合成分。试推导相应的生成式半监督学习算法。

解：

首先，我们假定：

- 数据 X 包含 $M = l + u$ 个样本： $X = \{\mathbf{x}_j\}, j = 1, \dots, M$
- 所有样本中共有 $|\mathcal{C}|$ 个类别： c_j 表示样本的类别， $c_j \in \mathcal{C}$
- 混合模型含有 N 个混合成分， $\{m_j = i\}, i = 1, \dots, N$ 表示样本 \mathbf{x}_j 可能的混合成分， θ_i 表示对应混合成分的模型参数，则相应模型可以表示为 $f(\mathbf{x}_j | \theta_i) = p(\mathbf{x}_j | m_j = i, \theta_i) = p(\mathbf{x}_j | \theta_i)$

在此处：

$$\begin{aligned} LL(D_l \cup D_u) &= \sum_{(\mathbf{x}_i, c_j) \in D_l} \ln p(\mathbf{x}_j, c_j | \theta) + \sum_{\mathbf{x}_i \in D_u} \ln p(\mathbf{x}_j | \theta) \\ &= \sum_{(\mathbf{x}_i, c_j) \in D_l} \ln \sum_{i=1}^N \alpha_i p(c_j | \mathbf{x}_j, m_j = i, \theta_i) p(\mathbf{x}_j | m_j = i, \theta_i) + \sum_{\mathbf{x}_i \in D_u} \ln \sum_{i=1}^N \alpha_i p(\mathbf{x}_j | m_j = i, \theta_i) \\ &= \sum_{(\mathbf{x}_i, c_j) \in D_l} \ln \sum_{i=1}^N \alpha_i p(c_j | \mathbf{x}_j, m_j = i, \theta_i) f(\mathbf{x}_j | \theta_i) + \sum_{\mathbf{x}_i \in D_u} \ln \sum_{i=1}^N \alpha_i f(\mathbf{x}_j | \theta_i) \end{aligned}$$

我们采用广义混合模型（The Generalized Mixture Model, GM），采用高斯分布作为混合成分，来推导 EM 算法的更新参数。

显然，此时：

$$f(\mathbf{x}_j | \theta_i) = p(\mathbf{x}_j | \theta_i) = p(\mathbf{x}_j | \mu_i, \Sigma_i)$$

则第一个式子变为：

$$LL(D_l \cup D_u) = \sum_{(\mathbf{x}_i, c_j) \in D_l} \ln \sum_{i=1}^N \alpha_i p(c_j | \mathbf{x}_j, m_j = i, \mu_i, \Sigma_i) p(\mathbf{x}_j | \mu_i, \Sigma_i) + \sum_{\mathbf{x}_i \in D_u} \ln \sum_{i=1}^N \alpha_i p(\mathbf{x}_j | \mu_i, \Sigma_i)$$

代入 GM 公式，得：

$$LL(D_l \cup D_u) = \sum_{(\mathbf{x}_i, c_j) \in D_l} \ln \sum_{i=1}^N \alpha_i \beta_{c_j|i} p(\mathbf{x}_j | \mu_i, \Sigma_i) + \sum_{\mathbf{x}_i \in D_u} \ln \sum_{i=1}^N \alpha_i p(\mathbf{x}_j | \mu_i, \Sigma_i)$$

我们的目的是要求得最优的 $\alpha_i, \beta_{c_j|i}, \mu_i, \Sigma_i$ 使上式取得最大值。

对于混合系数 α_i ，除了要最大化 $LL(D_l \cup D_u)$ ，还应满足隐含条件： $\alpha_i \geq 0$ ， $\sum_{i=1}^N \alpha_i = 1$ ，因此考虑对 $LL(D_l \cup D_u)$ 使用拉格朗日乘子法，变为优化： $LL(D_l \cup D_u) + \lambda(\sum_{i=1}^N \alpha_i - 1)$ ，代入 $LL(D_l \cup D_u)$ 的计算式，得到：

$$\frac{\partial LL(D_l \cup D_u)}{\partial \alpha_i} = \sum_{\mathbf{x}_j \in D_l} \frac{\beta_{c_j|i} \cdot p(\mathbf{x}_j | \mu_i, \Sigma_i)}{\sum_{i=1}^N \alpha_i \cdot \beta_{c_j|i} \cdot p(\mathbf{x}_j | \mu_i, \Sigma_i)} + \sum_{\mathbf{x}_j \in D_u} \frac{p(\mathbf{x}_j | \mu_i, \Sigma_i)}{\sum_{i=1}^N \alpha_i \cdot p(\mathbf{x}_j | \mu_i, \Sigma_i)} + \lambda = 0$$

令：

$$p(m_j = i | c_j, \mathbf{x}_j, \mu_i, \Sigma_i) = \frac{\alpha_i \cdot \beta_{c_j|i} \cdot p(\mathbf{x}_j | \mu_i, \Sigma_i)}{\sum_{i=1}^N \alpha_i \cdot \beta_{c_j|i} \cdot p(\mathbf{x}_j | \mu_i, \Sigma_i)}$$

同时，将高斯模型代入方程，得：

$$p(m_j = i | \mathbf{x}_j, \mu_i, \Sigma_i) = \frac{\alpha_i \cdot p(\mathbf{x}_j | \mu_i, \Sigma_i)}{\sum_{i=1}^N \alpha_i \cdot p(\mathbf{x}_j | \mu_i, \Sigma_i)}$$

$$0 = \sum_{\mathbf{x}_j \in D_l} p(m_j = i | c_j, \mathbf{x}_j, \mu_i, \Sigma_i) + \sum_{\mathbf{x}_j \in D_u} p(m_j = i | \mathbf{x}_j, \mu_i, \Sigma_i) + \alpha_i \cdot \lambda$$

令上式对所有高斯混合成分求和：

$$\begin{aligned} 0 &= \sum_{\mathbf{x}_j \in D_l} \sum_{i=1}^N p(m_j = i | c_j, \mathbf{x}_j, \mu_i, \Sigma_i) + \sum_{\mathbf{x}_j \in D_u} \sum_{i=1}^N p(m_j = i | \mathbf{x}_j, \mu_i, \Sigma_i) + \alpha_i \cdot \lambda \\ &= \sum_{\mathbf{x}_j \in D_l} 1 + \sum_{\mathbf{x}_j \in D_u} 1 + \lambda \\ &= M + \lambda \end{aligned}$$

令 $\lambda = -M$ ，将其带入上式，得：

$$\alpha_i = \frac{1}{M} \cdot \left(\sum_{\mathbf{x}_j \in D_l} p(m_j = i | c_j, \mathbf{x}_j, \mu_i, \Sigma_i) + \sum_{\mathbf{x}_j \in D_u} p(m_j = i | \mathbf{x}_j, \mu_i, \Sigma_i) \right)$$

对于高斯分布，其偏导具有如下性质：

$$\frac{\partial p(\mathbf{x} | \mu_i, \Sigma_i)}{\partial \mu_i} = p(\mathbf{x} | \mu_i, \Sigma_i) \cdot \Sigma_i^{-1} \cdot (\mu_i - \mathbf{x})$$

$$\frac{\partial p(\mathbf{x} | \mu_i, \Sigma_i)}{\partial \Sigma_i} = p(\mathbf{x} | \mu_i, \Sigma_i) \cdot \Sigma_i^{-2} \cdot ((\mathbf{x} - \mu_i)(\mathbf{x} - \mu_i)^\top - \Sigma_i)$$

求偏导，得：

$$\begin{aligned} \frac{\partial LL(D_l \cup D_u)}{\partial \mu_i} &= \sum_{\mathbf{x}_j \in D_l} \frac{\alpha_i \cdot \beta_{c_j|i} \cdot p(\mathbf{x}_j | \mu_i, \Sigma_i)}{\sum_{i=1}^N \alpha_i \cdot \beta_{c_j|i} \cdot p(\mathbf{x}_j | \mu_i, \Sigma_i)} \cdot \Sigma_i^{-1} \cdot (\mu_i - \mathbf{x}_j) + \sum_{\mathbf{x}_j \in D_u} \frac{\alpha_i \cdot p(\mathbf{x}_j | \mu_i, \Sigma_i)}{\sum_{i=1}^N \alpha_i \cdot p(\mathbf{x}_j | \mu_i, \Sigma_i)} \cdot \Sigma_i^{-1} \cdot (\mu_i - \mathbf{x}_j) \\ &= \sum_{\mathbf{x}_j \in D_l} p(m_j = i | c_j, \mathbf{x}_j, \mu_i, \Sigma_i) \cdot \Sigma_i^{-1} \cdot (\mu_i - \mathbf{x}_j) + \sum_{\mathbf{x}_j \in D_u} p(m_j = i | \mathbf{x}_j, \mu_i, \Sigma_i) \cdot \Sigma_i^{-1} \cdot (\mu_i - \mathbf{x}_j) \\ &= \Sigma_i^{-1} \cdot \left(\sum_{\mathbf{x}_j \in D_l} p(m_j = i | c_j, \mathbf{x}_j, \mu_i, \Sigma_i) \cdot (\mu_i - \mathbf{x}_j) + \sum_{\mathbf{x}_j \in D_u} p(m_j = i | \mathbf{x}_j, \mu_i, \Sigma_i) \cdot (\mu_i - \mathbf{x}_j) \right) \end{aligned}$$

继续计算：

$$\begin{aligned} \mu_i &= \frac{1}{M\alpha_i} \cdot \left(\sum_{\mathbf{x}_j \in D_l} \mathbf{x}_j \cdot p(m_j = i | c_j, \mathbf{x}_j, \mu_i, \Sigma_i) + \sum_{\mathbf{x}_j \in D_u} \mathbf{x}_j \cdot p(m_j = i | \mathbf{x}_j, \mu_i, \Sigma_i) \right) \\ \frac{\partial LL(D_l \cup D_u)}{\partial \Sigma_i} &= \sum_{\mathbf{x}_j \in D_l} \frac{\alpha_i \cdot \beta_{c_j|i} \cdot p(\mathbf{x}_j | \mu_i, \Sigma_i)}{\sum_{i=1}^N \alpha_i \cdot \beta_{c_j|i} \cdot p(\mathbf{x}_j | \mu_i, \Sigma_i)} \cdot \Sigma_i^{-2} \cdot ((\mathbf{x}_j - \mu_i)(\mathbf{x}_j - \mu_i)^\top - \Sigma_i) \\ &\quad + \sum_{\mathbf{x}_j \in D_u} \frac{\alpha_i \cdot p(\mathbf{x}_j | \mu_i, \Sigma_i)}{\sum_{i=1}^N \alpha_i \cdot p(\mathbf{x}_j | \mu_i, \Sigma_i)} \cdot \Sigma_i^{-2} \cdot ((\mathbf{x}_j - \mu_i)(\mathbf{x}_j - \mu_i)^\top - \Sigma_i) \\ &= \sum_{\mathbf{x}_j \in D_l} p(m_j = i | c_j, \mathbf{x}_j, \mu_i, \Sigma_i) \cdot \Sigma_i^{-2} \cdot ((\mathbf{x}_j - \mu_i)(\mathbf{x}_j - \mu_i)^\top - \Sigma_i) \\ &\quad + \sum_{\mathbf{x}_j \in D_u} p(m_j = i | \mathbf{x}_j, \mu_i, \Sigma_i) \cdot \Sigma_i^{-2} \cdot ((\mathbf{x}_j - \mu_i)(\mathbf{x}_j - \mu_i)^\top - \Sigma_i) \\ \Sigma_i &= \frac{1}{M\alpha_i} \cdot \left(\sum_{\mathbf{x}_j \in D_l} p(m_j = i | c_j, \mathbf{x}_j, \mu_i, \Sigma_i) \cdot ((\mathbf{x}_j - \mu_i)(\mathbf{x}_j - \mu_i)^\top) \right. \\ &\quad \left. + \sum_{\mathbf{x}_j \in D_u} p(m_j = i | \mathbf{x}_j, \mu_i, \Sigma_i) \cdot ((\mathbf{x}_j - \mu_i)(\mathbf{x}_j - \mu_i)^\top) \right) \end{aligned}$$

对于混合系数 $\beta_{k|i}$ ，除了要最大化 $LL(D_l \cup D_u)$ ，还应满足隐含条件： $\beta_{k|i} \geq 0$ ，

$\sum_{k=1}^{|C|} \beta_{k|i} = 1$ ，因此考虑对 $LL(D_l \cup D_u)$ 使用拉格朗日乘子法，变为优化：

$LL(D_l \cup D_u) + \lambda(\sum_{k=1}^{|C|} \beta_{k|i} - 1)$ ，代入 $LL(D_l \cup D_u)$ 的计算式，得到：

$$\frac{\partial LL(D_l \cup D_u)}{\partial \beta_{k|i}} = \sum_{\mathbf{x}_j \in D_l \wedge c_j=k} \frac{\alpha_i \cdot p(\mathbf{x}_j \mid \mu_i, \Sigma_i)}{\sum_{i=1}^N \alpha_i \cdot \beta_{c_j|i} \cdot p(\mathbf{x}_j \mid \mu_i, \Sigma_i)} + \lambda = 0$$

$$\begin{aligned} 0 &= \sum_{\mathbf{x}_j \in D_l \wedge c_j=k} \frac{\alpha_i \cdot \beta_{k|i} \cdot p(\mathbf{x}_j \mid \mu_i, \Sigma_i)}{\sum_{i=1}^N \alpha_i \cdot \beta_{c_j|i} \cdot p(\mathbf{x}_j \mid \mu_i, \Sigma_i)} + \beta_{k|i} \cdot \lambda \\ &= \sum_{\mathbf{x}_j \in D_l \wedge c_j=k} p(m_j = i \mid c_j, \mathbf{x}_j, \mu_i, \Sigma_i) + \beta_{k|i} \cdot \lambda \end{aligned}$$

$$\begin{aligned} 0 &= \sum_{k=1}^{|\mathcal{C}|} \sum_{\mathbf{x}_j \in D_l \wedge c_j=k} p(m_j = i \mid c_j, \mathbf{x}_j, \mu_i, \Sigma_i) + \sum_{k=1}^{|\mathcal{C}|} \beta_{k|i} \cdot \lambda \\ &= \sum_{\mathbf{x}_j \in D_l} p(m_j = i \mid c_j, \mathbf{x}_j, \mu_i, \Sigma_i) + \lambda \\ \lambda &= - \sum_{\mathbf{x}_j \in D_l} p(m_j = i \mid c_j, \mathbf{x}_j, \mu_i, \Sigma_i) \end{aligned}$$

最终得到：

$$\beta_{k|i} = \frac{\sum_{\mathbf{x}_j \in D_l \wedge c_j=k} p(m_j = i \mid c_j, \mathbf{x}_j, \mu_i, \Sigma_i)}{\sum_{\mathbf{x}_j \in D_l} p(m_j = i \mid c_j, \mathbf{x}_j, \mu_i, \Sigma_i)}$$